

Comparaison du rehaussement de vaisseaux sanguins appliqués aux images médicales 3D

Jonas Lamy

June 14, 2022
Version: Draft 0.1

Université Lyon 2

CleanThesis

LIRIS
LIRIS
Clean Thesis Group (CTG)

Traitement d'images

Comparaison du rehaussement de vaisseaux sanguins appliqués aux images médicales 3D

Jonas Lamy

- | | |
|--------------------|--|
| <i>1. Reviewer</i> | Jane Doe
Department of Clean Thesis Style
Clean Thesis Style University |
| <i>2. Reviewer</i> | John Doe
Department of Clean Thesis Style
Clean Thesis Style University |
| <i>Supervisors</i> | Nicolas Passat and Bertrand Kerautret and Odysée Merveille |

June 14, 2022

Jonas Lamy

Comparaison du rehaussement de vaisseaux sanguins appliqués aux images médicales 3D

Traitement d'images, June 14, 2022

Reviewers: Jane Doe and John Doe

Supervisors: Nicolas Passat and Bertrand Kerautret

Université Lyon 2

Clean Thesis Group (CTG)

LIRIS

LIRIS

LIRIS, Bât C, 5 avenue Pierre Mendès France, Bron

69000 and Lyon

Abstract

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Abstract (different language)

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Contents

1	Etat de l'art	1
1.1	Segmentation	1
1.1.1	Segmentation classique	2
1.1.2	Segmentation deep learning 3D	10
1.2	Rehaussement	12
1.2.1	Introduction	12
1.3	Espace d'échelle	14
1.3.1	Espace Gaussien	15
1.3.2	granulométrie	17
1.3.3	Flux	20
1.3.4	Multi-échelle	22
1.4	Familles de rehaussement	22
1.4.1	Morphologie	22
1.4.2	Phase	23
1.4.3	Wavelets	24
1.4.4	Hessienne	24
1.4.5	Diffusion	25
1.5	Bilan et orientation des travaux	25
	List of Figures	27
	List of Tables	29
	List of Listings	31

Etat de l'art

” *Un petit chapitre pour le doctorant, un grand chapitre pour l'humanité*

— **Doctorant anonyme**
(Citation temporaire)

1.1 Segmentation

Après l'acquisition des images provenant des systèmes d'IRM et de Tomodensitométrie, se pose la question de la visualisation des données. En effet, les images obtenues sont des matrices 3D et une visualisation 3D naïve ne permet de discerner que l'enveloppe extérieure d'un volume. Parmi les techniques de visualisation, la plus simple et la moins coûteuse, revient à considérer le volume 3D comme une suite de coupes 2D. On peut ainsi visualiser la totalité des tissus d'un volume de manière itérative. Cette méthode oblige cependant les médecins à une gymnastique mentale pour reconstituer, dans leur esprit, l'organe 3D étudié. Une autre méthode consiste à visualiser les objets les plus saillants de l'image. La technique la plus utilisée, la MIP (maximum intensity projection), consiste à lancer pour chaque pixels d'un plan p_i , un rayon traversant le volume de donnée. L'intensité maximale des voxel le long de ce rayon est ensuite assignée à p_i . Cette méthode à l'avantage de faire ressortir les éléments les plus intenses de l'image et convient particulièrement à des structures mis en valeur par un agent de contraste. Elle est aussi très simple à implémenter et est peu coûteuse en ressources de calcul. Cependant, cette méthode fait perdre toute perception de profondeur, à cause de la projection, ce qui peut perturber l'analyse des structures. Ce dernier désavantage peut toutefois être contourné par l'utilisation d'une MIP dans une scène 3D contenant le volume 3D de l'image et une camera. La projection s'effectuant alors sur le plan de la caméra et il est possible de déplacer l'observateur autour du volume qui permet grâce au mouvement de rétablir implicitement cette information de profondeur. L'utilisation de la MIP pour l'étude d'un organe, peut tout de fois être parasité par des organes adjacents plus intenses, comme par exemple les os de la cage toracique.



Fig. 1.1: visualisation en coupe



Fig. 1.2: Maximaly intensity projection (mip). L'intensité maximale est rétroprojeté le long du rayon sur le plan d'origine. La MIP peut s'effectuer en utilisant les bords de l'image, où le plan de la caméra dans une scène 3D

A noter que ces deux méthodes ne sont pas invasives, dans le sens où aucune transformation n'est appliquée à l'image originale.

Bien que la vue en coupes 2D et la MIP offrent une visualisation convenable dans de nombreux cas, celles-ci peuvent se révéler insuffisante pour la représentation de structures complexes ou pour des tâches de mesures volumétriques. Dans ce cas, il est nécessaire d'extraire les structures d'intérêts de l'information superflue qui les entourent. C'est ce processus d'extraction que l'on nomme segmentation.

1.1.1 Segmentation classique

L'automatisation de la segmentation pour les images médicales est une tâche complexe. Elle doit répondre à des problématiques variées, provenant à la fois des conditions d'acquisition de l'image ??, de forme de l'organe et de l'extraction d'éléments sémantiques haut niveau. Ces contraintes peuvent mener à l'élaboration de chaînes de traitements proposant un nombre d'étapes importants. Ainsi, Marcan [Mar+14] propose un pipeline de segmentation en 16 étapes mélangeant, filtrage du bruit, sélection des éléments pertinents par masques et analyses des composantes connexes pour la segmentation des vaisseaux du foie. Goceri [GSG17] propose une méthode en 14 étapes allant de la partition en régions d'intérêts à l'étirement du contraste (contrast stretching) afin de différencier vaisseaux hépatiques des tissus du foie.

Une taxonomie précise des méthodes de segmentation est difficile à établir tant les publications présentent différentes combinaisons de briques algorithmiques. Lesage [Les+09] propose une décomposition des étapes de segmentation sous la forme de 3 grands thèmes : Les modèles d'intensités et modèles géométriques, les descripteurs d'images et les schéma d'extractions. Les modèles constituent l'ensemble des hypothèses permettant d'identifier l'objet à segmenter. Les descripteurs reposent sur des caractéristiques spécifiques de l'image qui permettent de mesurer l'écart de similarité entre les données et le modèle. Enfin, le schéma d'extraction permet de choisir le seuil idéal de segmentation en fonction des caractéristiques de l'image et du/des modèle(s) choisi(s).

Dans cette partie, nous explicitons les briques algorithmiques classiquement utilisées pour la segmentation des vaisseaux. Nous prenons comme parti pris d'explorer le pipeline à l'envers, c'est à dire, de présenter les schémas d'extractions courants, puis les descripteurs communément utilisés pour finir par les modèles de représentations. Nous pourrions ainsi amener progressivement le rehaussement de vaisseaux qui se trouve à cheval entre les deux dernières catégories.

Schéma d'extraction

Une segmentation est avant tout une méthode permettant de classer si un pixel appartient à un objet d'intérêt. Les schémas d'extractions proposent un ensemble de cadres pour automatiser ce choix.

Courbes de niveaux La méthode des courbes de niveau (level set) permet à l'origine de simuler la propagation d'une onde ou d'un fluide dans un milieu. Appliquée à la segmentation, elle permet de faire s'étendre en fonction du temps un contour jusqu'à ce qu'un critère d'arrêt soit atteint. Ce critère d'arrêt est souvent exprimé comme une énergie à minimiser. Cette énergie peut reposer sur des modélisations des structures à segmenter, des caractéristiques de l'image ou des propriétés sur la courbure du front de propagation de l'onde.

Le suivi des pixels d'un contour évoluant avec le temps est une tâche non triviale en particulier lorsque la topologie du contour change. C'est par exemple le cas lorsqu'un contour se divise en deux contours distincts. Les levels sets permettent de contourner ce problème en définissant un contour implicite comme l'intersection de deux surfaces. La première surface correspond à l'image vue comme une carte de hauteur et la seconde courbe ϕ correspond aux critères de partition. La dynamique




Fig. 1.3: Courbes de niveaux

d'évolution du contour implicite est g  r   par l'  l  vation de la courbe ϕ en fonction du temps.

Rochery et al. [RJZ06] propose une formulation des levels set d'ordre sup  rieur contenant une   nergie de continuit   et une caract  risation des discontinuit  s lui permettant de segmenter des structures lin  aires rompues par endroits.

Li [Li+11] utilise les levels set pour segmenter un objet malgr  s des intensit  s non homog  nes, pour cela il d  finit un crit  re de classification local au voisinage des pixels afin d'estimer un champ de biais d'intensit   qui est ensuite incorpor   dans l'  nergie de propagation. Zeng [Zen+18a] utilise une m  thode de contour actifs (sp  cification du level set) dont le crit  re est estim      la fois la coh  rence entre les r  gions d  limit  es par le contour et une carte de contours bas  e sur le gradient.

Une sous cat  gorie des levels set est la m  thode d  velopp  e par Kass et al. [KWT88] des contours actifs (aussi appel  s snake). Cette m  thode formule l'  nergie contr  lant la propagation du contour comme la somme pond  r  e d'une   nergie interne et d'une   nergie externe    minimiser. Cette   nergie a ensuite connues de nombreuses variations comme Wang et al. [WMS12] qui propose un mod  le minimisant 3   nergies : une   nergie bas  e courbure, une   nergie bas  e sur les gradients d'intensit   et une   nergie bas  e sur un mod  le cylindrique.

Graph cut Une image peut-  tre repr  sent  e sous la forme d'un graphe. Dans ce graph, les noeuds sont les pixels et les ar  tes encodent une relation de similarit   entre les pixels. Cette relation peut   tre spatiale o   plus complexe. Dans ce contexte, segmenter un objet ou une r  gion revient    trouver la coupure qui maximise la vraisemblance    l'int  rieur de chaque partition et minimise la vraisemblance entre deux partitions relativement    un crit  re.

Zeng [Zen+17] propose un raffinement par graph cut d'une segmentation initiale, en utilisant un crit  re de r  gion bas  e sur la vraisemblance logarithmique (negative log likelihood) et un crit  re de bordure bas  e sur le flux (voir SEC. ??).




Fig. 1.4: Graph cut, le graph cut nécessite des graines afin de définir les deux régions à raffiner

Ensembles flous Le choix d'une délimitation entre fond et segmentation n'est pas toujours aisé, en particulier dans les images médicales où les bords des objets à segmenter sont assez mal définis. La théorie des ensembles flous permet de modéliser cette incertitude. Au lieu d'associer une classe binaire aux pixels, on associe à chaque pixel une probabilité d'appartenance à chaque classes définie pour l'image. Un critère flou est ensuite construit afin de choisir une classe finale par pixels.

Zhang et al. [Zha+18] définit un critère de connectivité floue composé d'un critère d'adjacence floue, et de similarité à un vaisseau.

Radojevic et al.[RSM15] propose une application à deux classes et propose une mesure de flou d'un ensemble basé sur les classes multiplicatives. Cette mesure permet de définir le degrés d'ambiguïté d'un ensemble flou servant à attribuer une classe finale aux pixels.

[Zha+18], Fuzzy connectedness = Fuzzy adjacency (FAD) + fuzzy affinity (FA) + fuzzy connectivity (FC). FAD = local similarity of a voxel pair. $\mu_\alpha(c, d)$ monotonic increasing function, h1=exponentielle de la moyenne centrée et h2=exponentielle de la différence centrée. w_1 et w_2 sont des pondérations tel que $w_1 + w_2 = 1$. une vesselness (Zhang) est utilisée à la place de l'intensité des vaisseaux. [Cap+14]

[RSM15] two class application, membership function as $\mu^v = K1 - Features(P)$ and $\mu^{nv} = K2 - (1 - Features(P))$. measure of fuzzy set = Multiplicative class : $H_*(\mu_F) = K \sum_{i=1}^n g(\mu_F(x_i))$. Fuziness degree = ambiguity of fuzzy set. defuzzyfication end μ^v vs μ^{nv} .

[Sig+14]

Caractéristiques

Les caractéristiques extraites de l'image permettent de fournir des descripteurs quantifiables qui peuvent être incorporés dans les schémas d'extractions vus à la section précédente.

Les caractéristiques les plus employés sont les caractéristiques différentielles. Celles-ci permettent d'étudier les variations de dynamiques dans l'image et permettent notamment d'extraire des informations géométriques locales.

Opérateurs dérivatifs Le premier descripteur différentiel est la dérivée première, aussi appelé gradient. Celui-ci peut-être calculé de différentes manières (différences finies, convolution de noyau gaussiens dérivés, etc.) et fourni une information sur la variation des intensités des pixels au niveau local. Le gradient est une quantité scalaire et s'exprime comme la somme des dérivées partielles de l'image. Là où le gradient permet de quantifier les changements d'intensités, l'utilisation des dérivées partielles sous forme de champ de vecteurs gradients, permet d'obtenir une information de direction du gradient. Agam et al. [AAW05] propose un filtre des vaisseaux basé sur un champ de vecteurs régularisé.

En particulier, une représentation compacte de l'orientation de la géométrie locale autour d'un pixel est le tenseur de structure EQ. ??.,

$$T(f) = \begin{bmatrix} t_{11} & t_{12} & t_{13} \\ t_{21} & t_{22} & t_{23} \\ t_{31} & t_{32} & t_{33} \end{bmatrix} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_1 \partial x_3} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \frac{\partial^2 f}{\partial x_2 \partial x_3} \\ \frac{\partial^2 f}{\partial x_3 \partial x_1} & \frac{\partial^2 f}{\partial x_3 \partial x_2} & \frac{\partial^2 f}{\partial x_3^2} \end{bmatrix}$$

La dérivée seconde permet d'obtenir des informations sur la courbure local de l'image autour d'un pixel. Le laplacien, qui s'exprime comme la divergence du gradient, permet d'évaluer la ressemblance du voisinage local à une sphère. [Wan+20]

Tout comme pour le gradient, le laplacien est une quantité sans information de direction, on utilise la matrice des dérivées partielles secondes, la hessienne, pour encoder les informations de direction.

Les moments sont des descripteurs basé sur l'intégration. Ils permettent de décrire la dispersion d'une variable aléatoire (en l'occurrence, l'intensité du voisinage d'un pixel). Les moments permettent d'obtenir des informations sur l'espérance, la variance, l'assymétrie, etc. Ceux-ci se définissent par :

$$M_{qpr} = \sum_{i=0}^{N_x} \sum_{j=0}^{N_y} \sum_{k=0}^{N_z} x^p y^q z^r f(x, y, z) dx dy dz \quad (1.1)$$

Moments Boldak et al. [Bol+03] propose une segmentation des vaisseaux par tracking basé sur des moments géométriques.

Flux Adossés aux champs de vecteurs gradients et aux modèles, les caractéristiques de flux permettent d'étudier la dynamique d'intensité autour des contours d'un objet. Ces caractéristiques ont été introduites par Valilevsky [VS02]. Ces descripteurs nécessitent un choix préalable d'un modèle géométrique d'objet à segmenter et sont relativement rigides.

Modèles

La définition de modèles pour l'objet à segmenter nous permet de mesurer la fidélité d'une région décrite par des caractéristiques.

Les modèles sont en général au nombre de trois, les modèles d'intensités, les modèles géométriques et les modèles à base d'atlas.

Les modèles d'intensités sont construits sur l'intensité prédites des structures à segmenter. Pour l'angiographie, une des hypothèse de base est que les vaisseaux ont une intensité différente des tissus qui les entourent. En particulier pour l'angiographie avec agent de contraste, les vaisseaux sont supposés clairs sur fond foncé. Dans le cas contraire, e.g vaisseaux foncés sur fond clair, il suffit d'inverser les niveaux de gris de l'image pour retomber sur l'hypothèse initiale.

Les modèles d'intensités peuvent être construit en amont ou itérativement au cours de la segmentation. He [He+13] propose une segmentation itérative par seuillage automatique Otsu et étirement de contraste afin d'élargir peu à peu le modèle d'intensité sous jacent. Bukenya [bukenya2016_heart_otsu_top_hat_hessian], étend cette méthode à la 3D et la renforce avec des modèles géométriques afin de faciliter la détection des petits vaisseaux de faible intensité, De la même manière BahadarKhan, utilise une méthode hybride [BAS16].

Parmi les méthodes qui tirent parti des modèles d'intensité, on peut citer les méthodes reposant sur la MIP, qui permettent de projeter et d'isoler les vaisseaux saillants, avant de les identifier dans le volume initial par rétro-propagation.




Fig. 1.5: Tracking, fluoroscopy

La méthode des K plus proches voisins permet de construire automatiquement une distribution d'intensité initiale et permet de séparer facilement les classes fond et vaisseaux et d'identifier les classes d'intensité ambiguës mélangeant vaisseaux et autres tissus. Zeng [Zen+18b] utilise les K plus proche voisins pour servir de segmentation initiale à une croissance de région. On retrouve la même pratique chez Goceri [GSG17]. Ces méthodes montrent leurs limites lorsque le contraste des vaisseaux est faible ou que l'image étudiée ne contient pas d'intensités homogènes pour les mêmes tissus d'un même organe, comme c'est le cas pour l'IRM.

Pour répondre à ces problématiques, des méthodes de rehaussement d'image peuvent être utilisées, tel que CLAHE, utilisé par exemple par Sigurosson [Sig+14]. Des méthodes plus poussées, permettent d'estimer les biais d'intensités comme Pavan [Pav+18] pour l'imagerie du foie. Ils peuvent aussi directement être exprimés dans les schéma d'extraction, comme le level set de Li [Li+11].

Les constructions itératives de modèles d'intensités sont particulièrement présents dans les techniques de tracking de vaisseaux, consistant à segmenter de proche en proche la ligne centrale des vaisseaux. Pour ces applications, les modèles bayésiens permettent de construire un modèle d'intensité à partir des voxels du chemin déjà parcouru et de prédire l'intensité attendu à la prochaine étape de l'algorithme. Ces méthodes conviennent particulièrement au tracking d'axones pour la fluoroscopie [RSM15][RM17].

Les modèles d'intensités ne prennent pas en compte la forme des objets détectés et peuvent ainsi détecter des objets de même intensités d'étant pas des vaisseaux. Par exemple, pour des vaisseaux faiblement contrastés et bruités, la distribution d'intensité des vaisseaux risque de chevaucher la distribution du bruit.

Les modèles géométriques viennent compléter les modèles d'intensités. En effet, l'aspect spécifique des vaisseaux qui forment des structures curvilignes, les rendent le plus souvent très différents des autres organes.

Les modèles les plus basiques sont les modèles en forme de disques, ou sphériques pour leurs équivalents 3D [LC08]. Les modèles sphériques sont limités par le fait

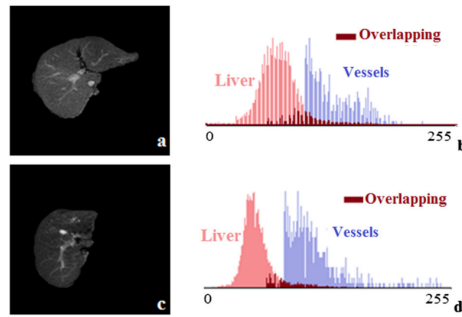



Figure 4. MR image through the liver (a, c); gray level values of pixels in the liver parenchyma (shown in pink), vessels (shown in purple), and overlapping of gray level values (shown in red) (b, d).

Fig. 1.6: Histogrammes d'intensité des tissus du foie, en bleu l'intensité des vaisseaux, en rouge l'intensité des tissus du foie (image placeholder, Goceri[2016])



ap

Fig. 1.7: Modèles géométriques basiques, sphère, cylindre, tubulaire et curvilinéaire

que les éléments sphériques et tubulaires ne sont pas dissociables. Des variantes cylindriques ont aussi été proposées dans la littérature Tyrrell [tyrrell2007_superEllipsoid], Esneault [ELD09], Cetin [CU15]. Le modèle prédominant est le modèle tubulaire développé dans le chapitre CH.?? Celui-ci a l'avantage d'être plus général et flexible que le modèle cylindrique.

La littérature propose aussi un ensemble de modèles déformables, sans à priori de formes. Ceux-ci nécessitent le plus souvent un point d'initialisation donné manuellement ou déterminé de manière automatique. Ces modèles sont contraints par une énergie qui définit les limites de déformation du modèle. La difficulté principale est de trouver un terme de contrainte permettant d'éviter un écoulement du modèle hors des vaisseaux. Mille et al. [MC09] combine un critère de tubularité, un critère d'homogénéité de régions et un critère de lissage du contour.

Enfin, une famille de modèle provenant de la morphologie mathématique modélise les vaisseaux comme un ensemble de chemins curvilinéaires.[HBT05]

Enfin, les modèles à base d'atlas sont des modèles construits à base de mesures préalables. Ils sont construits en amont de la méthode de segmentation et représentent une connaissance "en moyenne" d'un modèle géométrique, d'intensité ou plus fréquemment d'une localisation dans l'espace. Les modèles d'atlas sont particulièrement adaptés à des structures rigides qui présentent peu de diversités anatomiques comme les vaisseaux du cerveau, Passat et al. [Pas+06].

1.1.2 Segmentation deep learning 3D

A partir de 2015, les réseaux de neurones ont pris une place prépondérante dans la littérature de la segmentation grâce à l'apparition des modèles de réseaux profonds, de l'augmentation de la puissance de calculs et d'un nombre important de données annotées. Pour le médical cette installation se fait de manière plus lente mais assurée. La classification modèle, caractéristiques, schéma d'extraction est plus complexe à appliquer en deep learning. Celui-ci repose sur trois éléments, l'architecture du réseau, les données utilisées associées et le critère de convergence du réseau.

Architecture

Les réseaux de neurones convolutifs ont pris une place prépondérante dans la littérature. Ces méthodes reposent sur l'apprentissage automatique de caractéristiques de l'image. Pour cela, un grand nombre d'exemples est montré au réseau qui apprend à donner la réponse attendue. Deux types d'entraînement sont principalement utilisés, l'entraînement supervisé par paires {image d'entrée, vérité terrain} et l'entraînement non supervisé avec des images en entrée et une énergie à minimiser, permettant de contraindre la sortie du réseau. L'erreur de classification du réseau est ensuite propagée à travers chaque couche qui le compose par rétro-propagation du gradient d'erreur.

Les réseaux convolutionnels sont une représentation compacte de réseaux plus anciens, les perceptrons multicouches. Ils ont aussi la propriété d'être invariant à la translation.

AlexNet [KSH12] et VGG [SZ14] marquent le début des réseaux de convolution profonds (CNN) avec des performances remarquables pour la classification d'images couleurs. Avec la création de réseaux de plus en plus profonds, l'entraînement se révèle de plus en plus difficile à cause de la diminution croissante de l'erreur à rétro-propager au fur et à mesure des couches. Ce problème a été résolu plus

tard par le modèle ResNet [He+16], qui propose des couches résiduels permettant d'introduire une redondance de l'information. De la même manière, le modèle DenseNet [Hua+17] propose de réutiliser des caractéristiques tout au long du réseau, aliant redondance et légèreté du réseau.

Ce sont les réseaux convolutionnels complets (FCNN), en particulier l'architecture d'auto-encodeur U-Net [RFB15] qui a percé dans le milieu médical en permettant de segmenter de manière précise des organes. Ce modèle propose une architecture composé d'un encodeur et d'un décodeur symétriques, donnant au réseau sa forme en U caractéristique. Des "skip connections", permettent de propager les détails de l'encodeur au décodeur.

Un large pannel de variantes de ce réseau a été proposé dans la littérature, combinant ResNet [Yu+19], DenseNet [Li+18], en utilisant plusieurs réseaux à des résolutions différentes ou en proposant des branches spécialisées.

L'entraînement d'un réseau est possible seulement si l'on est capable de définir une mesure de l'erreur produite entre la sortie d'un réseau et le résultat attendu. Cette fonction de coût, aussi appelée fonction de perte (loss function) a aussi largement été étudiée dans la littérature. Les premières fonctions de coût reposent sur la distance L2. Celle-ci a été largement remplacée par une fonction de coût empruntée de la théorie de l'information, la cross entropie. Pour la segmentation, Sudre [Sud+17] propose une fonction de perte, la "Dice loss" basée sur le recouvrement entre la vérité terrain et la segmentation du réseau. Plusieurs métriques ont été dérivées de la Dice loss, tel que la fonction de perte de Tversky ou focale. Ces fonctions permettent de régler la sensibilité de la métrique au taux de faux positifs ou de faux négatifs. Une revue des fonctions de perte pour la segmentation est proposé par [Jad20]. Plus récemment des travaux ont exploré l'introduction de critères topologiques (composantes connexes) afin de limiter la fragmentation des segmentations [Hu+19],[Clo+19],[Ven+17]. Ces méthodes restent très couteuses en temps.

Le nombre des données joue un rôle crucial dans la performance des réseaux de neurones. Pour l'imagerie médicale, deux problèmes se posent. Le premier concerne l'acquisition et la collecte des données. En effet, un examen médical n'est réalisé que lorsque celui-ci est jugé nécessaire. De plus, la législation concernant la collecte, le stockage et l'anonymisation des données est de plus en plus stricte depuis la RGPD.

Un second problème qui concerne particulièrement les méthodes supervisées est l'annotation des données collectées. Pour la segmentation d'images médicales,



Fig. 1.8: placeholder

cette vérité terrain est nécessaire pour à la fois valider les modèles utilisés et faire converger les réseaux. Cependant, l'annotation est une tâche longue et fatigante qui nécessite la mobilisation d'un ou de plusieurs spécialistes.

Plusieurs méthodes permettent de contourner partiellement ce problème. La plus utilisée est l'augmentation de données, [LK16]. Celle-ci utilise des données existantes pour appliquer des changements d'intensités ou des déformations géométriques afin de créer artificiellement des données supplémentaires.

D'autres méthodes comptent sur l'utilisation de données partielles, ou d'annotations complètes sur une partie des données seulement [Taj+20]. Certains auteurs ont exploré le transfert de style afin de générer des images d'une modalité grâce à des images d'autres modalités [Cha+17],[Huo+18],[Per+19].

1.2 Rehaussement

1.2.1 Introduction

Parmi les méthodes de segmentation des vaisseaux sanguins une grande majorité utilise une étape de pré-traitement consistant à faciliter la segmentation des vaisseaux. Cette étape augmente de manière significative le contraste des vaisseaux et atténue le signal de toutes les autres structures. Ces filtres portent le nom de "filtres de rehaussement de vaisseaux" (vesselness filters). Ces filtres combinent des modèles d'intensités et de géométries spécifiques aux vaisseaux avec des descripteurs d'images. De par leur positionnement en amont des pipelines de segmentation, ils ont une influence directe sur le choix et les performances des schémas d'extractions.

Un filtre de rehaussement peut se baser sur plusieurs stratégies pour améliorer le signal des vaisseaux :

- la distribution des intensités
- la géométrie des structures
- la hiérarchie des structures

En effet, pour la tomodensitométrie comme pour l'IRM, certaines hypothèses physiques sont applicables aux vaisseaux.

Premièrement, pour l'angiographie avec injection d'agent de contraste, on considère que les vaisseaux ont une intensité supérieure aux tissus qui les entourent. Cette hypothèse, bien que souvent vraie, se retrouve limitée en pratique. En effet, cette hypothèse dépend des conditions liées au temps d'acquisition et de la vascularisation de l'organe étudié. Plus l'acquisition est longue et les échanges vasculaires nombreux dans l'organe, plus l'agent de contraste se diffuse dans celui-ci. Ce processus peut aller jusqu'à rendre l'organe totalement uniforme sans possibilité de différencier les tissus qui le compose. Comme discuté dans la section SEC. ?? du chapitre CH. ?? l'utilisation d'agent de contrastes ne garanti pas un aspect uniforme des vaisseaux. Cet aspect varie en fonction de la concentration de l'agent de contraste dissous dans le sang. Par conséquent, plus le diamètre des vaisseaux est réduit, plus la concentration, et donc le contraste, est faible. Pour des tronçons de vaisseaux de même taille, la viscosité du sang ou la géométrie des vaisseaux peut aussi faire s'accumuler l'agent de constrate dans des régions spécifiques.

Une fois l'hypothèse d'intensité posée, on peut établir de nouvelles hypothèses sur la géométrie des vaisseaux. L'hypothèse la plus courante est d'asimiler les vaisseaux à des cylindres ou des tubes soumis à des contraintes géométriques plus ou moins relâchées. Cette hypothèse peut se montrer suffisante lorsque l'on ne considère qu'un seul tronçon de vaisseaux. En réalité, dans un réseau vasculaire, chaque tronçons peut avoir des formes et diamètres variés, et les tranches successives d'un même tronçon ne sont pas forcément homogène. De plus, les vaisseaux sont interconnectés entre eux, formant aux jonctions des objets géométriques qui sortent du cadre des hypothèses initiales.

Enfin, on peut établir des hypothèses basées sur la hiérarchie des vaisseaux. La plupart du temps, les organes sont alimentés par un ou des vaisseaux rincipaux, les artères, relativement larges qui se subdivisent ensuite pour alimenter les différentes régions de l'organe. Cette subdivision prend la plupart du temps la forme d'une bifurcation, c'est à dire un vaisseaux se séparant en deux vaisseaux (pour les artères, et inversement pour les veines). Plus rarement, on peut observer des N-furcations, comme la trifurcation de la carotide. Cette division des vaisseaux est la plupart du temps accompagnée d'un changement de diamètre qui dépend du sens du flux




Fig. 1.9: exemple de filtre de rehaussement de vaisseaux

sanguin. Dans certains organes, on peut ainsi vérifier des propriétés topologiques. Par exemple pour le foie, le réseau vasculaire porte peut être assimilé à un graph sans cycle, voir à un arbre dont les noeuds sont les bifurcations et les arêtes les vaisseaux.

1.3 Espace d'échelle

La détection d'un réseau vasculaire dans sa totalité implique de détecter des vaisseaux de différentes tailles. En effet, les plus gros vaisseaux peuvent faire plusieurs dizaines de voxels de diamètres tandis que les vaisseaux les plus fins, atteignant les limites de la résolution des capteurs, peuvent mesurer jusqu'à un voxel de diamètre. Il n'est pas envisageable de ré-écrire un algorithme pour chaque taille de vaisseaux, c'est pourquoi des cadres théoriques, appelés *espace d'échelle* ont été formulés. Ces espaces d'échelles permettent d'établir un cadre uniforme pour sélectionner les structures d'une image à une échelle donnée. Trois espaces d'échelles sont couramment associés au réhaussement de vasculaire dans la littérature : L'espace d'échelle gaussien, l'espace d'échelle granulométrique et l'espace d'échelle de flux orienté.

1.3.1 Espace Gaussien

Lindenberg introduit la théorie de l'espace d'échelles gaussien dans [lindeberg2013_scale]. Dans cette théorie, à l'échelle la plus basse, la totalité des structures sont présentes, et les détails les plus fins sont présents. Au fur et à mesure que l'échelle augmente, les détails sont lissés pour ne laisser que les maxima locaux correspondants aux formes les plus grandes. Ainsi, l'échelle minimale correspond à l'image initiale et




Fig. 1.10: Lissage gaussien, les structures de taille égales ou supérieures à σ sont conservées alors que les structures de taille inférieures disparaissent




Fig. 1.11: couverture d'une distribution normale

l'échelle maximale correspond à une image uniforme. Il a été démontré que les noyaux gaussien étaient les seuls noyaux permettant de passer d'une échelle fine à une échelle grossière sans provoquer l'apparition de nouvelles structures. De plus, un mécanisme identique a été observé dans le fonctionnement du champ visuel.

$$gauss(x, y, \sigma_x, \sigma_y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{x^2 + y^2 + z^2}{2(\sigma_x + \sigma_y + \sigma_z)}\right) \quad (1.2)$$

La sélection de l'échelle dans un espace gaussien se fait par le choix de l'écart-type σ de la gaussienne. La plupart du temps on considère un espace d'échelle uniforme, $\sigma_x = \sigma_y = \sigma_z$. Il faut noter que pour un σ donné, la taille des structures n'est pas supérieure ou égale à σ mais plutôt supérieure ou égale à $\alpha\sigma$. En effet, en empruntant le formalisme des statistiques, l'intervalle de confiance, c'est-à-dire la couverture d'une distribution normale, correspond à 34.1% pour $\sigma = 1$, 68% pour $\sigma = 2$ et 99.7% pour $\sigma = 3$. Ainsi, pour $\sigma = 1$ on détectera des objets de rayon 3σ et de diamètre 6σ .



Fig. 1.12: débordement du signal des structures larges sur les structures de plus petite tailles

L'espace gaussien se prête particulièrement bien à la modélisation des vaisseaux. En effet, la formulation de la gaussienne correspond bien à l'effet combiné des hypothèses de vaisseaux cylindriques et de la diminution d'intensité des vaisseaux au fur et à mesure que l'on s'éloigne de leur centre. En particulier pour un vaisseau parfait de diamètre 3σ , les maxima locaux se situent le long de sa ligne centrale.

De plus, la gaussienne se prête très bien à une analyse locale de la géométrie basée sur la dérivation. Elle assure en effet les hypothèses de continuité du support de l'image et permet de combiner lissage et dérivation de l'image en une seule étape par dérivation du noyau gaussien.

Enfin, le lissage a l'avantage d'apporter une certaine robustesse au bruit et de compenser la perte locale de signal.

L'espace gaussien a toutefois des défauts. Le lissage de l'image implique nécessairement un étalement de toutes les structures qui peuvent par conséquent cacher des structures voisines de plus petites tailles. Ce phénomène est particulièrement observé lorsque plusieurs échelles sont étudiées. De même, deux structures adjacentes de même tailles peuvent fusionner, et ainsi créer une seule réponse, là où deux objets existaient initialement.

Confirmation sur données réelles TODO:Expériences vérifiant en pratique la relation $3\sigma = \text{diametre}$

1.3.2 granulométrie

La granulométrie est l'étude des tailles des particules d'un échantillon. En chimie, on utilise par exemple la technique du tamisage. Elle permet, grâce à un tamis et une grille dont on contrôle la taille du maillage, de ne conserver que des particules dont la taille est trop grosse pour passer à travers le tamis.

Un principe similaire est applicable en morphologie mathématique sur les images binaires et par extension en niveau de gris.

Erosion et dilatation

Deux opérations élémentaire, la dilatation et l'érosion, permettent de définir les opérations nécessaires pour définir un espace d'échelle morphologique. Les définitions qui vont suivre sont des opérations binaires relatives à des objets blancs sur fond noir.

Definitions Soit deux ensembles définis dans Z^3 avec les composants $a = (a_1, a_2, a_3)$ et $b = (b_1, b_2, b_3)$.

La *translation* de A par $x = (x_1, x_2)$, noté $(A)_x$ est définie par :

$$(A)_x = \{c | c = a + x, \text{ pour } a \in A\}. \quad (1.3)$$

On définit la *reflection* de B , dénoté \hat{B} par :

$$(\hat{B}) = \{x | x = -b, \text{ pour } b \in B\}. \quad (1.4)$$

Le complémentaire de l'ensemble A est défini par :

$$(A^c) = \{x | x \notin A\}. \quad (1.5)$$

La différence de deux ensemble A et B , noté $A - B$, est défini par:

$$(A - B) = \{x | x \in A, x \notin B\} = A \cap B^c. \quad (1.6)$$

dilatation En utilisant les propriétés précédentes, la dilatation s'exprime de la manière suivante :

$$A \oplus B = \{x | (\hat{B}_x \cap A) \neq \emptyset\} \quad (1.7)$$




Fig. 1.13: Exemple de dilatation




Fig. 1.14: Exemple d'érosion

La dilatation de A par B est l'ensemble de tous les déplacements de \hat{B} tel qu'il y ai au moins un pixel de recouvrement entre A et \hat{B} . Cette opération permet de faire grossir une structure en fonction de la forme de B .

L'ensemble B est couramment appelé *élément structurant*.

erosion L'opération oposée à la dilatation est l'érosion.

$$A \ominus B = x | (B)_x, \subseteq A \quad (1.8)$$

L'érosion de A par B est l'ensemble de tous les points x tel que B translaté de x est inclus dans A .

Fermeture et ouverture

A partir des opérations d'érosion et de dilatation, on peut définir des opération composites, l'ouverture et la fermeture.

Fermeture L'ouverture est définie comme la dilatation de A par B suivi de l'érosion de A par B .

$$A \bullet B = (A \oplus B) \ominus B \quad (1.9)$$




Fig. 1.15: Exemple de fermeture




Fig. 1.16: Exemple d'ouverture

Cet opérateur est utilisé pour boucher les trous dont la surface est inférieure à la surface de l'élément structurant. L'érosion qui suit la dilatation permet d'assurer que la taille reste stable.

Ouverture L'ouverture est définie comme l'érosion de A par B suivi de la dilatation de A par B .

$$A \circ B = (A \ominus B) \oplus B \quad (1.10)$$

Cet opérateur est utilisé pour supprimer les structures de tailles inférieures à la surface de l'élément structurant. La dilatation qui suit l'érosion permet d'assurer que la taille des éléments restent stable.

L'ouverture permet de construire un espace d'échelle paramétré par la taille de l'élément structurant. Cet espace ne souffre pas d'une fusion parasite des structures adjacentes.

1.3.3 Flux

Comme nous l'avons vu dans la section SEC. 1.3.1, l'espace d'échelle gaussien peut provoquer des débordements de structures sur d'autres, plus petites. On peut limiter se problème en utilisant un cadre différent, celui de l'analyse des flux.

Si l'on considère un champ de vecteur V , par exemple un fluide, ou un champ de gradient pour une image, on définit le flux passant à travers la surface S orienté par sa normale \vec{n}_s comme l'intégrale de la somme du produit scalaire entre le vecteur de flux \vec{v} et la normale à la surface \vec{n} .

$$flux_S = \int_S \langle \vec{v}, \vec{n} \rangle d\rho \quad (1.11)$$

On peut appliquer le calcul de flux à la surface d'un objet fermé. En particulier, des structures en forme de disques ou de sphères ont été particulièrement utilisées pour l'analyse de vaisseaux sanguins. On peut en effet contrôler directement le diamètre d'une sphère pour détecter les objets de la taille voulue. Cette formulation de l'échelle diffère des méthodes précédentes, car les objets tubulaires ne sont détectés que pour une échelle donnée, là où les deux autres techniques conservent les objets à l'échelle donnée et aux échelles supérieures. Elle a aussi l'avantage de limiter l'analyse du flux à la surface de la sphère et donc de produire une réponse qui ne déborde pas.

La précision du calcul de l'intégrale de flux dépend du nombre d'échantillonnages effectués sur S . Plus celui-ci est grand, plus le calcul est coûteux. De plus, plus l'échelle sélectionnée est grande, et donc plus la surface de la sphère est grande, plus le nombre d'échantillonnage requis est important.

Law propose une formulation élégante du calcul de flux dans le domaine de Fourier afin de réduire drastiquement le temps de calcul par rapport à l'implémentation naïve [law2009_efficient_implementation].

Pour y parvenir, law propose d'exprimer le calcul de flux sous la forme d'une convolution dans le domaine temporel. L'avantage de la convolution est double, on évite l'étape d'échantillonnage sur la surface et la convolution s'exprime comme une multiplication dans le domaine de Fourier. On peut exprimer le calcul de flux en terme de volume et non plus en terme de surface grâce au théorème de la divergence qui établit une égalité entre le flux à la surface d'un objet et le flux à l'intérieur de son volume. Ainsi :

$$flux_{\partial C} = \int_{\partial C} \langle \vec{v}, \vec{n} \rangle d\rho \equiv \int_C \Delta I d\nu \quad (1.12)$$

Plus précisément :

$$f_s(x, y, z) = \int_{R_s} \vec{v}(x+t, y+p, z+q) \cdot \vec{n}_{(t,p,q)} dA \quad (1.13)$$

avec R_s une région sphérique de rayon s ; dA une surface infinitésimale sur la surface ∂R_s ; $\vec{n}_{(t,p,q)}$ le vecteur normal à dA à la position (t, p, q) ; et \vec{v} le gradient de l'image I . \vec{v} est obtenu à partir de l'image I lissée par un noyau Gaussien afin d'assurer la dérivabilité du signal de I . $\vec{v} = \nabla(g * I)$.

Qui est équivalent à :

$$f_s(x, y, z) = \int_{R_s} \vec{\text{div}}(\vec{v}(x+t, y+p, z+q)) dt dp dq \quad (1.14)$$

$$= \int_{\omega} d_s(t, p, q) [\vec{\text{div}}(\vec{v}(x+t, y+p, z+q))] dt dp dq \quad (1.15)$$

où ω est le domaine entier de l'image et $d_s(t, p, q)$ correspond à la fonction porte sphérique définie par :

$$d_s(x, y, z) = [\sqrt{x^2 + y^2 + z^2} \leq s] \quad (1.16)$$

Ainsi, $f_s(x, y, z)$ peut être exprimé sous forme de convolution :

$$f_s(x, y, z) = \int_{\omega} d_s(t, p, q) [\vec{\text{div}}(\vec{v}(x+t, y+p, z+q))] dt dp dq \quad (1.17)$$

$$= \int_{\omega} d_s(t, p, q) (\Delta(g * I(x+t, y+p, z+q))) dt dp dq \quad (1.18)$$

$$= \int_{\omega} d_s(-t, -p, -q) (\Delta(g * I(x+t, y+p, z+q))) dt dp dq \quad (1.19)$$

$$= d_s * \Delta g * I(x, y, z) \quad (1.20)$$

$$= I * h_s(x, y, z) \quad (1.21)$$

$$(1.22)$$

avec $*$ l'opérateur de convolution, Δ l'opérateur laplacien.

Et dans le domaine de Fourier:




Fig. 1.17: flux sur la surface d'une sphère

$$FFT(I * h_s(x, y, z)) = FFT(I) \cdot H_s(u, v, w) \quad (1.23)$$

$$= FFT(I) \cdot [(j2\pi)^2 \left(\left(\frac{u}{N_x} \right)^2 + \left(\frac{v}{N_y} \right)^2 + \left(\frac{w}{N_z} \right)^2 \right)] \quad (1.24)$$

$$\cdot [\exp(-((\frac{u}{N_x})^2 + (\frac{v}{N_y})^2 + (\frac{w}{N_z})^2)2(\pi\sigma)^2)] \quad (1.25)$$

1.3.4 Multi-échelle

TODO: Voir si cette partie est à développer ici ou dans filtres, chapitre 4.

1.4 Familles de rehaussement

Plusieurs grandes familles de rehaussement sont présentes dans la littérature.

1.4.1 Morphologie

Le rehaussement à base d'opérateurs morphologiques s'articule autour de deux familles, la composition d'éléments structurants rigides et l'utilisation de chemins curvilinéaires flexibles.

La composition d'éléments structurants rigides s'effectue la plupart du temps avec des boules et des cylindres. Les cylindres permettent de couvrir les parties curvilignes des



Fig. 1.18: bowler hat transform proposée par Sazak et al.

vaisseaux, tandis que les boules couvrent les jonctions. Une composition d'ouvertures avec ces éléments est ensuite utilisée pour récupérer le réseau vasculaire. Sazak propose un schéma de ce type en 2 dimensions [**sazak_2D**] puis en 3D [**sazak_3D**] et compare son efficacité contre du rehaussement à base de tenseurs de phases et hessiens. Cette méthode bien que simple à mettre en pratique, nécessite plusieurs itérations avec des rotations des éléments structurants afin de capturer toutes les orientations des structures tubulaires. Cette méthode peut devenir coûteuse en 3D.

L'un des défauts de la méthode précédente est la rigidité des éléments structurants qui ne permettent pas toujours de capturer les variations de formes des vaisseaux. Heijmans [HBT05] propose une famille d'éléments structurants flexibles dont la forme est définie par une grille d'adjacences. Des améliorations successives de cet algorithme ont été proposées : XX propose une implémentation efficace de l'algorithme en $O(XX)$, Cokelaer propose une version robuste au bruit en autorisant des discontinuités dans l'élément structurant, Merveille et al. itère en proposant un classement de l'orientation des chemins afin de segmenter les vaisseaux dans des images 2D et 3D.

1.4.2 Phase

Une image peut-être à la fois vue comme une matrice de pixels et comme un signal discret en 2 ou 3 dimensions. Lorsque l'on considère la représentation sous forme de signal on peut décomposer celui-ci en deux éléments indépendants : L'amplitude, correspondant à l'intensité des pixels et la phase, correspondant à la distance entre deux pics de deux signaux. La phase étant une mesure relative à la position des pics, elle ne prend pas en compte l'amplitude de ceux-ci et présente donc une invariance aux changements d'intensités. Oppenheim et al. [OL81] démontre l'importance de ces caractéristiques de l'image et une représentation




Fig. 1.19: Fourier decomposition of the green signal, at some points the underlying signals phase are synchronised resulting in a high phase congruency

Plusieurs structures de vesselness se basent sur cette propriété pour la détection des vaisseaux. Obara et al. [Oba+12] utilise un tenseur de structure basé sur le contraste de phase. Les valeurs propres de ce tenseur permettent ensuite d'exprimer une mesure de tubularité.

$$toto = tenseurdephase \quad (1.26)$$

Les filtres quadratiques reposent aussi sur l'utilisation de la phase en décomposant l'image en bandes de fréquences.

Les filtres basés phases sont invariants aux changements d'intensités mais sont sensibles aux changements de fréquences et sont donc sensibles au bruit.

1.4.3 Wavelets

1.4.4 Hessienne

La matrice hessienne est la matrice des dérivées seconde de l'image en un pixel. Celle-ci permet d'exprimer la courbure locale autour d'un point.

Les valeurs propres et vecteurs propres de la hessienne permettent de quantifier l'orientation, le sens et l'amplitude du voisinage d'un point.

La simplicité de la Hessienne a permis l'émergence de nombreuses modélisations de rehaussement.

En 3D, une structure tubulaire parfaite peut-être exprimée par les valeurs propres. Soit $\lambda_1, \lambda_2, \lambda_3$ tel que $|\lambda_1| \leq |\lambda_2| \leq |\lambda_3|$ alors un tube parfait est modélisée par :

$$\lambda_1 \approx 0, \lambda_1 \ll \lambda_2 \approx \lambda_3 \quad (1.27)$$

Ces équations sont valables dans un contexte spécifique. Lorsque le σ de l'espace d'échelle coïncide avec la taille d'une structure tubulaire, la ligne centrale de celle-ci devient un maxima local. Le vecteur propre $\lambda_1 \approx 0$ correspond à la direction du tube. La magnitude λ_1 est proche de zéro car le gradient dans cette direction est presque nul. Dans les deux directions principales de la tranche, l'intensité du tube décroissant rapidement au fur et à mesure que l'on s'éloigne du centre les valeurs propres λ_2 et λ_3 sont élevées.

Cet outils a permis le développement de nombreuses techniques de réhaussement basé sur les valeurs propres Erdt, Li, Frangi, Sato, Jerman, Meijering, etc. Dont les principales contributions sont présentées dans le chapitre SEC. ??

1.4.5 Diffusion

Les méthodes de diffusions sont une classe un peu à part dans le rehaussement des vaisseaux. L'objectif des frameworks de diffusion est d'améliorer le signal des vaisseaux en homogénéisant leur intensités et en renforçant leurs bordures. Pour cela, les filtres de diffusion proposent un schéma de lissage itératif qui prennent en compte la géométrie des structures à lisser.

HDGS [Men+09] (Hybrid diffusion with continuous switch), propose un lissage hybride combinant lissage isotropique de régions et lissage basé sur les bordures. Ces deux lissages sont combinés avec une mesure de la géométrie locale afin d'appliquer une combinaison linéaire des deux filtres la plus adaptée.

VED [MVN06] (Vessel enhancement diffusion) propose un lissage basé sur les méthodes de rehaussement hessiens. Ce cadre permet ainsi d'homogénéiser la réponse de n'importe quelle filtre de rehaussement hessien sans perdre de structures tubulaires.

Ces méthodes itératives sont coûteuses en temps de calcul et nécessitent une paramétrisation supplémentaire pour contrôler la force du lissage ainsi que le nombre d'itérations nécessaire.

1.5 Bilan et orientation des travaux

Parmi ces techniques de segmentation, choisir les plus adaptés au traitement des vaisseaux hépatiques pour l'imagerie CT et plus particulièrement l'IRM n'est pas simple. En effet, les papiers résumant l'état de l'art présentent un comparatif sans

détailler l'impact de chaque catégorie sur la segmentation. De plus, ses comparaisons sont faites sur des bases de données différentes permettant tout comparatif entre articles impossible.

Parmi les pipelines de segmentations reviennent de manière régulière les méthodes de réhaussement de vaisseaux. Celles-ci étant employées en amont des pipelines de segmentation, leur impact est particulièrement important pour le reste de la segmentation. Cependant, ces filtres ont assez peu été étudiés seuls dans la littérature. Pour le foie un comparatif pour l'imagerie Ct existe mais celui-ci concerne des annotations partielles (landmarks) et ne constituent pas une quantification précise d'un réhaussement pour la segmentation.

L'un des premiers travaux de cette thèse a donc été de rassembler, et comparer ces filtres entre eux. Ce travail s'est ensuite consolidé et constitue aujourd'hui l'apport principal de cette thèse.

Bibliography

- [AAW05] Gady Agam, Samuel G Armato, and Changhua Wu. “Vessel tree reconstruction in thoracic CT scans with application to nodule detection”. In: *IEEE Transactions on Medical Imaging* 24.4 (2005), pp. 486–499.
- [BAS16] Khan BahadarKhan, Amir A Khaliq, and Muhammad Shahid. “A morphological hessian based approach for retinal blood vessels segmentation and denoising using region based otsu thresholding”. In: *PloS one* 11.7 (2016), e0158996.
- [Bol+03] C Boldak, Y Rolland, C Toumoulin, and JL Coatrieux. “An improved model-based vessel tracking algorithm with application to computed tomography angiography”. In: *Biocybernetics And Biomedical Engineering* 23.1 (2003), pp. 41–64.
- [Cap+14] Laura Caponetti, Giovanna Castellano, M Teresa Basile, and Vito Corsini. “Fuzzy mathematical morphology for biological image segmentation”. In: *Applied intelligence* 41.1 (2014), pp. 117–127.
- [CU15] Suheyly Cetin and Gozde Unal. “A higher-order tensor vessel tractography for segmentation of vascular structures”. In: *IEEE transactions on medical imaging* 34.10 (2015), pp. 2172–2185.
- [Cha+17] Agisilaos Chartsias, Thomas Joyce, Rohan Dharmakumar, and Sotirios A Tsaftaris. “Adversarial image synthesis for unpaired multi-modal cardiac data”. In: *International workshop on simulation and synthesis in medical imaging*. Springer. 2017, pp. 3–13.
- [Clo+19] James R Clough, Nicholas Byrne, Ilkay Oksuz, et al. “A topological loss function for deep-learning based image segmentation using persistent homology”. In: *arXiv preprint arXiv:1910.01877* (2019).
- [ELD09] Simon Esneault, Cyril Lafon, and Jean-Louis Dillenseger. “Liver vessels segmentation using a hybrid geometrical moments/graph cuts method”. In: *IEEE Transactions on Biomedical Engineering* 57.2 (2009), pp. 276–283.
- [GSG17] Evgin Goceri, Zarine K Shah, and Metin N Gurcan. “Vessel segmentation from abdominal magnetic resonance images: adaptive and reconstructive approach”. In: *International journal for numerical methods in biomedical engineering* 33.4 (2017), e2811.
- [He+16] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “Deep residual learning for image recognition”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, pp. 770–778.

- [He+13] Xiaochuan He, Zhenkuan Pan, Qian Dong, and Guodong Wang. “Veins Segmentation and Three-Dimensional Reconstruction from Liver CT Images Using Multilevel OTSU Method”. In: *2013 Seventh International Conference on Image and Graphics*. IEEE. 2013, pp. 248–251.
- [HBT05] Henk Heijmans, Michael Buckley, and Hugues Talbot. “Path openings and closings”. In: *Journal of Mathematical Imaging and Vision* 22.2 (2005), pp. 107–119.
- [Hu+19] Xiaoling Hu, Fuxin Li, Dimitris Samaras, and Chao Chen. “Topology-preserving deep image segmentation”. In: *Advances in Neural Information Processing Systems* 32 (2019).
- [Hua+17] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. “Densely connected convolutional networks”. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, pp. 4700–4708.
- [Huo+18] Yuankai Huo, Zhoubing Xu, Shunxing Bao, et al. “Adversarial synthesis learning enables segmentation without target modality ground truth”. In: *2018 IEEE 15th international symposium on biomedical imaging (ISBI 2018)*. IEEE. 2018, pp. 1217–1220.
- [Jad20] Shruti Jadon. “A survey of loss functions for semantic segmentation”. In: *2020 IEEE Conference on Computational Intelligence in Bioinformatics and Computational Biology (CIBCB)*. IEEE. 2020, pp. 1–7.
- [KWT88] Michael Kass, Andrew Witkin, and Demetri Terzopoulos. “Snakes: Active contour models”. In: *International journal of computer vision* 1.4 (1988), pp. 321–331.
- [KSH12] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. “Imagenet classification with deep convolutional neural networks”. In: *Advances in neural information processing systems* 25 (2012).
- [LC08] Max WK Law and Albert Chung. “Three dimensional curvilinear structure detection using optimally oriented flux”. In: *European conference on computer vision*. Springer. 2008, pp. 368–382.
- [Les+09] David Lesage, Elsa D Angelini, Isabelle Bloch, and Gareth Funka-Lea. “A review of 3D vessel lumen segmentation techniques: Models, features and extraction schemes”. In: *Medical image analysis* 13.6 (2009), pp. 819–845.
- [Li+11] Chunming Li, Rui Huang, Zhaohua Ding, et al. “A level set method for image segmentation in the presence of intensity inhomogeneities with application to MRI”. In: *IEEE transactions on image processing* 20.7 (2011), pp. 2007–2016.
- [Li+18] Xiaomeng Li, Hao Chen, Xiaojuan Qi, et al. “H-DenseUNet: hybrid densely connected UNet for liver and tumor segmentation from CT volumes”. In: *IEEE transactions on medical imaging* 37.12 (2018), pp. 2663–2674.
- [LK16] Paweł Liskowski and Krzysztof Krawiec. “Segmenting retinal blood vessels with deep neural networks”. In: *IEEE transactions on medical imaging* 35.11 (2016), pp. 2369–2380.

- [MVN06] Rashindra Manniesing, Max A Viergever, and Wiro J Niessen. “Vessel enhancing diffusion: A scale space representation of vessel structures”. In: *Medical image analysis* 10.6 (2006), pp. 815–825.
- [Mar+14] Marija Marcan, Denis Pavliha, Maja Marolt Music, et al. “Segmentation of hepatic vessels from MRI images for planning of electroporation-based treatments in the liver”. In: *Radiology and Oncology* 48.3 (2014), pp. 267–281.
- [Men+09] Adriënne M Mendrik, Evert-Jan Vonken, Annemarieke Rutten, Max A Viergever, and Bram van Ginneken. “Noise reduction in computed tomography scans using 3-D anisotropic hybrid diffusion with continuous switch”. In: *IEEE transactions on medical imaging* 28.10 (2009), pp. 1585–1594.
- [MC09] Julien Mille and Laurent D Cohen. “A local normal-based region term for active contours”. In: *International Workshop on Energy Minimization Methods in Computer Vision and Pattern Recognition*. Springer. 2009, pp. 168–181.
- [Oba+12] Boguslaw Obara, Mark Fricker, David Gavaghan, and Vicente Grau. “Contrast-independent curvilinear structure detection in biomedical images”. In: *IEEE Transactions on Image Processing* 21.5 (2012), pp. 2572–2581.
- [OL81] Alan V Oppenheim and Jae S Lim. “The importance of phase in signals”. In: *Proceedings of the IEEE* 69.5 (1981), pp. 529–541.
- [Pas+06] Nicolas Passat, Christian Ronse, Joseph Baruthio, J-P Armspach, and Claude Maillot. “Magnetic resonance angiography: From anatomical knowledge modeling to vessel segmentation”. In: *Medical image analysis* 10.2 (2006), pp. 259–274.
- [Pav+18] Ana LM Pavan, Marwa Benabdallah, Marie-Ange Lebre, et al. “A parallel framework for HCC detection in DCE-MRI sequences with wavelet-based description and SVM classification”. In: *Proceedings of the 33rd Annual ACM Symposium on Applied Computing*. 2018, pp. 14–21.
- [Per+19] Christian S Perone, Pedro Ballester, Rodrigo C Barros, and Julien Cohen-Adad. “Unsupervised domain adaptation for medical imaging segmentation with self-ensembling”. In: *NeuroImage* 194 (2019), pp. 1–11.
- [RM17] Miroslav Radojević and Erik Meijering. “Automated neuron tracing using probability hypothesis density filtering”. In: *Bioinformatics* 33.7 (Jan. 2017), pp. 1073–1080. eprint: <https://academic.oup.com/bioinformatics/article-pdf/33/7/1073/25149870/btw751.pdf>.
- [RSM15] Miroslav Radojević, Ihor Smal, and Erik Meijering. “Automated neuron morphology reconstruction using fuzzy-logic detection and Bayesian tracing algorithms”. In: *2015 IEEE 12th International Symposium on Biomedical Imaging (ISBI)*. 2015, pp. 885–888.
- [RJZ06] Marie Rochery, Ian H Jermyn, and Josiane Zerubia. “Higher order active contours”. In: *International Journal of Computer Vision* 69.1 (2006), pp. 27–42.

- [RFB15] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-net: Convolutional networks for biomedical image segmentation”. In: *International Conference on Medical image computing and computer-assisted intervention*. Springer. 2015, pp. 234–241.
- [Sig+14] Eysteinn Már Sigurðsson, Silvia Valero, Jón Atli Benediktsson, et al. “Automatic retinal vessel extraction based on directional mathematical morphology and fuzzy classification”. In: *Pattern Recognition Letters* 47 (2014), pp. 164–171.
- [SZ14] Karen Simonyan and Andrew Zisserman. “Very deep convolutional networks for large-scale image recognition”. In: *arXiv preprint arXiv:1409.1556* (2014).
- [Sud+17] Carole H Sudre, Wenqi Li, Tom Vercauteren, Sebastien Ourselin, and M Jorge Cardoso. “Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations”. In: *Deep learning in medical image analysis and multimodal learning for clinical decision support*. Springer, 2017, pp. 240–248.
- [Taj+20] Nima Tajbakhsh, Laura Jeyaseelan, Qian Li, et al. “Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation”. In: *Medical Image Analysis* 63 (2020), p. 101693.
- [VS02] Alexander Vasilevskiy and Kaleem Siddiqi. “Flux maximizing geometric flows”. In: *IEEE transactions on pattern analysis and machine intelligence* 24.12 (2002), pp. 1565–1578.
- [Ven+17] Carles Ventura, Jordi Pont-Tuset, Sergi Caelles, Kevis-Kokitsi Maninis, and Luc Van Gool. “Iterative deep learning for network topology extraction”. In: *arXiv preprint arXiv:1712.01217* (2017).
- [Wan+20] Chenglong Wang, Masahiro Oda, Yuichiro Hayashi, et al. “Tensor-cut: A tensor-based graph-cut blood vessel segmentation method and its application to renal artery segmentation”. In: *Medical Image Analysis* 60 (2020), p. 101623.
- [WMS12] Chunliang Wang, Rodrigo Moreno, and Örjan Smedby. “Vessel segmentation using implicit model-guided level sets”. In: *MICCAI Workshop" 3D Cardiovascular Imaging: a MICCAI segmentation Challenge", Nice France, 1st of October 2012*. 2012.
- [Yu+19] Wei Yu, Bin Fang, Yongqing Liu, et al. “Liver vessels segmentation based on 3d residual U-NET”. In: *2019 IEEE International Conference on Image Processing (ICIP)*. IEEE. 2019, pp. 250–254.
- [Zen+18a] Ye-zhan Zeng, Sheng-hui Liao, Ping Tang, et al. “Automatic liver vessel segmentation using 3D region growing and hybrid active contour model”. In: *Computers in Biology and Medicine* 97 (2018), pp. 63–73.
- [Zen+18b] Ye-zhan Zeng, Sheng-hui Liao, Ping Tang, et al. “Automatic liver vessel segmentation using 3D region growing and hybrid active contour model”. In: *Computers in biology and medicine* 97 (2018), pp. 63–73.

- [Zen+17] Ye-zhan Zeng, Yu-qian Zhao, Ping Tang, et al. “Liver vessel segmentation and identification based on oriented flux symmetry and graph cuts”. In: *Computer methods and programs in biomedicine* 150 (2017), pp. 31–39.
- [Zha+18] Rui Zhang, Zhuhuang Zhou, Weiwei Wu, et al. “An improved fuzzy connectedness method for automatic three-dimensional liver vessel segmentation in CT images”. In: *Journal of healthcare engineering* 2018 (2018).

List of Figures

1.1 visualisation en coupe	2
1.2 Maximaly intensity projection (mip). L'intensité maximale est rétroprojeté le long du rayon sur le plan d'origine. La MIP peut s'effectuer en utilisant les bords de l'image, où le plan de la caméra dans une scène 3D	2
1.3 Courbes de niveaux	4
1.4 Graph cut, le graph cut nécessite des graines afin de définir les deux régions à raffiner	5
1.5 Tracking, fluoroscopy	8
1.6 Histogrammes d'intensité des tissus du foie, en bleu l'intensité des vaisseaux, en rouge l'intensité des tissus du foie (image placeholder, Goceri[2016])	9
1.7 Modèles géométriques basiques, sphère, cylindre, tubulaire et curvilinéaire	10
1.8 placeholder	13
1.9 exemple de filtre de rehaussement de vaisseaux	14
1.10 Lissage gaussien, les structures de taille égales ou supérieures à σ sont conservées alors que les structures de taille inférieures disparaissent	15
1.11 couverture d'une distribution normale	16
1.12 débordement du signal des structures larges sur les structures de plus petite tailles	16
1.13 Exemple de dilatation	18
1.14 Exemple d'érosion	18
1.15 Exemple de fermeture	19
1.16 Exemple d'ouverture	19
1.17 flux sur la surface d'une sphère	22
1.18 bowler hat transform proposée par Sazak et al.	23
1.19 Fourier decomposition of the green signal, at some points the underlying signals phase are synchronised resulting in a high phase congruency	24

List of Tables

List of Listings

